

CareX-GS: Capacity Reallocation in X-ray Gaussian Splatting for Extremely Sparse-View CT Novel View Synthesis

Abstract

极稀疏视角 CT 新视图合成旨在从极少量 X 射线投影生成未观测角度的投影图像，对超低剂量扫描、快速采集和受限扫描轨迹下的医学成像具有重要意义。现有基于 3D Gaussian Splatting 的 X-ray/CT 方法在稀疏视角下通常继续沿用传统 3DGS 的密化思路，并辅以优化稳定或几何先验来缓解性能退化。然而，我们发现这一密化策略并不适配 X-ray/CT 场景：骨骼与软组织交界等高对比解剖边界会在投影中产生剧烈灰度突变，沿用梯度驱动密化时，模型会在这些局部边界反复堆积细小高斯；与此同时，X 射线的穿透式成像又要求边界后方的低对比内部结构同样得到充分表达，最终导致表示容量被错误集中到边界附近。基于这一观察，本文提出 CareX-GS，一个面向极稀疏视角 CT 新视图合成的 X-ray Gaussian Splatting 容量重分配框架，通过空间先验播种 (Spatial Prior Seeding, SPS)、几何感知剪枝 (Geometry-aware Pruning, GAP) 和自适应密度调制 (Adaptive Density Modulation, ADM) 三个模块，分别在初始化、冗余回收和局部密度建模阶段重分配高斯表示容量。实验表明，该容量重分配策略在 5 个器官和全部稀疏协议上都能稳定提升新视图渲染质量，所有协议下的平均 PSNR 均优于对比方法，并在代表性设置下相对 R^2 -Gaussian 获得最高 0.39 dB 的增益。

1. 引言

极稀疏视角条件下的 CT 新视图合成 (novel view synthesis, NVS) 旨在从极少量 X 射线投影合成未观测角度的投影图像；由于 X 射线观测由体密度积分决定，这一任务与体重建天然耦合，同时也有望在采样受限时为医生补充未采集方向的观察视角，辅助解剖结构定位、病灶范围判断与快速成像预览。该任务具有明确的应用价值：减少采样视角可以降低辐射剂量、缩短扫描时间并减轻设备负担；而在剂量预

算严格、快速扫描、扫描轨迹受限或患者难以长时间配合等场景下，输入投影往往会被压缩到极低水平，使病例级优化更容易陷入欠定状态 [FDK84; AK84; WYD08]。与自然图像中的新视图合成不同，X 射线成像遵循穿透式辐射传输，像素观测是整条射线路径上衰减累积的结果，因此这一任务对初始化位置、空间分布和密度建模都更加敏感。

现有 sparse-view 3DGS 方法大多默认性能退化主要来自覆盖不足、优化不稳或几何误差，因此

通常通过继续密化并叠加额外模块来缓解性能下降。若抽象到 pipeline 层, 这类方法虽然表面模块不同, 但大体共享同一条优化骨干: 以误差/梯度驱动的高斯密化为中心, 再分别附加 coverage 补偿、协同正则或几何/物理先验。FSGS 通过 proximity-guided unpooling、伪视角和深度先验扩张覆盖范围 [ZFJW24], CoR-GS 通过双场 disagreement 与 co-pruning 稳定优化过程 [ZLY*24], DNGaussian 借助深度归一化缓解几何退化 [LZB*24]; 在 X-ray/CT 场景中, X-Gaussian 与 R^2 -Gaussian 又进一步补足了辐射高斯表示与积分偏差修正 [CLW*24; ZLC*24]。但这些方法本质上仍是在回答“如何让原有密化链路更稳、更准或更有先验”, 而没有改变这条链路本身: 一旦高误差或高梯度区域持续被视为最值得复制的位置, 高斯仍会不断向局部边界聚集。

然而, 这一密化策略并不完全适用于 X-ray/CT。CT 体空间并非由少量可见表面主导, 而是由不同组织密度连续占据; 骨骼与软组织交界等区域在投影中往往表现为更剧烈的灰度突变, 因此会被基于误差或梯度的密化持续识别为“最值得补点”的位置。结果是, 模型不断在这些边界周围插入更细小、更狭窄的高斯去追逐高频变化; 但与可见光遮挡场景不同, X 射线的穿透性又意味着边界后方的低对比内部组织同样参与成像, 不能被边缘表达所替代。换句话说, 极稀疏视角 CT 中的核心问题往往不是“高斯还不够多”, 而是“高斯被传统密化放到了不合适的位置”, 并进一步形成结构冗余与容量错配。

基于这一判断, 我们提出 CareX-GS, 一个面向极稀疏视角 CT 新视图合成的 X-ray Gaussian Splatting 容量重分配框架。我们的关键贡献首先是 pipeline 层的, 而不是单纯再增加几个辅助模块: 我们不再把额外能力叠加到同一条密化骨干上, 而是把极稀疏 CT 的优化流程改写为一条 coarse-to-fine allocation 链路, 即“先按解剖先验进行粗分配, 再回收边界冗余, 最后细化局部密度”。图 1 将代表性主流方法抽象为三类 pipeline: coverage 补偿型、协同约束型和先验校正型; 它们虽然使用不同模块, 但最终都围绕同一条 densification backbone 运转。相比

之下, CareX-GS 直接改写了 allocation 的顺序与粒度。具体到方法实现上, 这一新 pipeline 由空间先验播种 (Spatial Prior Seeding, SPS)、几何感知剪枝 (Geometry-aware Pruning, GAP) 和自适应密度调制 (Adaptive Density Modulation, ADM) 三个模块分别落地: SPS 利用 FDK 粗重建提供的解剖密度线索, 先把高斯放到更合适的区域; GAP 依据空间邻近度与梯度活跃性周期性回收由传统密化错误放大的局部冗余高斯; ADM 则通过一个在线联合优化的轻量分支, 利用位置相关上下文进一步修正保留高斯的密度分布。

我们的贡献可以概括为三点:

- 指出传统 3DGS 的密化策略并不适配 X-ray/CT: 高梯度解剖边界会反复吸引高斯复制, 从而造成局部结构冗余与表示容量错配。
- 提出 CareX-GS X-ray Gaussian Splatting 容量重分配框架, 在 pipeline 层将极稀疏 CT 的优化流程改写为一条 coarse-to-fine allocation 路线, 即“先粗分配、再回收、后细化”; 在方法层, 这一路线分别由 SPS、GAP 和 ADM 三个模块具体实现。
- 在多器官极稀疏 CT 场景中验证上述容量重分配策略能够稳定提升新视图渲染质量, 在全部稀疏协议上均取得最优平均 PSNR, 并相对 R^2 -Gaussian 获得最高 0.39 dB 的提升。

2. 相关工作

2.1. 极稀疏新视图合成

3D Gaussian Splatting 通过一组三维各向异性高斯显式表示场景, 并依赖可微分栅格化实现高效渲染, 在效率与质量之间取得了优于传统 NeRF 的平衡 [KKLD23]。自 2023 年提出以来, 3DGS 迅速扩展到结构化表示、抗锯齿渲染、动态建模与紧凑压缩等方向 [CW24; LYX*24; YCH*24; GL24; WRW*24; XLG*24; YGZ*24; NMKW24; RNSZ24]; 而在极稀疏 NVS 设定下, 相关方法则逐渐沿两条更清晰的主线展开: 一条是逐场景优化高斯表示, 另一条是用前馈网络直接从少量输入视图预测高斯原语。




Figure 1: *pipeline* 层的本质区别。前三类代表性方法虽然分别强调 *coverage* 补偿、协同约束或几何/物理先验，但都仍围绕同一条误差/梯度驱动的 *densification backbone* 运转，因此容易把容量持续吸附到高对比边界；*CareX-GS* 则把优化流程改写为一条 *coarse-to-fine allocation* 链路，即“粗分配 → 冗余回收 → 细调制”，直接在 *pipeline* 层重排高斯表示容量。

逐场景优化路线更接近原始 3DGS 的测试时优化范式，其内部又可按对失败原因的判断继续细分。FSGS 将性能退化主要归因于 *coverage* 不足，因此沿密化过程引入 proximity-guided unpooling、伪视角和单目深度先验来补点扩张 [ZFJW24]；CoR-GS 将问题视为单场优化不稳，通过双场 co-regularization 与 co-pruning 抑制几何分歧 [ZLY*24]；DNGaussian 则把重点放在稀疏视角下的几何恢复误差，并用全局-局部深度归一化显式注入几何先验 [LZB*24]。2025 年的 DropGaussian 和 GS-GS 又分别沿结构正则与生成式伪视角两条方向继续推进：前者通过随机丢弃与结构感知剪枝缓解训练视图过拟合，后者借助扩散模型在伪视角生成中补足未观测区域并强调跨视图一致性 [PRK25; KYW25]。

另一条主线是 generalizable/feed-forward Gaussian prediction，它把“少视角下如何补足几何与外观先验”的负担前移到大规模训练阶段。pixelSplat

通过图像对上的概率深度分布采样 Gaussian centers [CLTS24]，MVSplat 进一步用 plane-sweeping cost volume 聚合多视图对应关系 [CXZ*24]，DepthSplat 与 MonoSplat 则继续把深度估计和 monocular foundation priors 显式并入 Gaussian prediction，以增强几何稳定性与跨域泛化能力 [XPW*25; LFY*25]。总体上，无论是逐场景优化还是前馈重建，现有极稀疏 NVS 方法大多仍把性能瓶颈理解为 *coverage* 不足、几何不稳或先验缺失。相比之下，本文关注的 CT 体空间由连续密度占据，密化过程更容易在高对比解剖边界诱发局部冗余，因此关键不只是“生成更多高斯”，而是“把高斯放到更合适的空间位置，并把被边界吞噬的容量重新分配回来”。

2.2. X 射线新视图合成

传统 CT 重建方法大体可以分为解析法与迭代法。以 FDK 为代表的解析方法依赖滤波反投影，计算效率

高,但在稀疏视角下容易产生条纹伪影;SART 等迭代方法能够更稳健地引入先验约束,但计算成本较高 [FDK84; AK84]。在 2023 年之后,围绕 sparse-view X-ray/CT 的学习型方法逐渐可以按表示形式归纳为两条主线:隐式衰减场,以及显式辐射原语。

隐式场路线延续 neural field / neural attenuation field 的建模思路,但开始更强调 X 射线的结构性与扫描几何。Structure-Aware Sparse-View X-ray 3D Reconstruction (SAX-NeRF) 通过 Lineformer 和 masked local-global ray sampling 同时建模 3D 线段依赖与 2D 投影上下文,在新视图合成与 CT 重建上统一优化 [CWY*24]; Geometry-Aware Attenuation Learning 则把多视图 2D 特征沿扫描几何反投影到 3D 体特征图,再用 3D 解码器恢复 CBCT 体数据,代表了从病例级自监督优化转向 population-level encoder-decoder inference 的另一条路线 [LFL*25]。这类方法保持了连续体密度场的表达能力,但通常仍依赖密集射线采样或较重的 3D 体解码。

显式路线则试图为 X 射线的穿透与衰减过程重新设计原语表示。X-Gaussian 首次较系统地把 radiative Gaussian 和可微 X-ray rasterization 引入 projection-domain NVS,核心目标是高效合成未观测视角投影 [CLW*24]; R²-Gaussian 进一步把重点转向 reconstruction consistency,显式修正 3D-to-2D 积分偏差并引入可微体素化,使辐射高斯能够直接服务于 sparse-view tomography [ZLC*24]。在此基础上,后续工作又沿几条更细的路线展开:X-Field 以材料感知椭球和路径分割强化物理一致性 [WTW*25], DGR 用离散 Gaussian functions 直接重建体素网格 [WLG*25], GR-Gaussian 从图结构梯度修正极稀疏条件下的针状伪影,而 X²-Gaussian 则把 radiative Gaussian 扩展到连续时间 4D CT [YMS*25; YCZ*25]。整体来看,X-ray/CT 研究正在从“借用可见光场景表示”逐步转向“围绕穿透成像、衰减累积和重建一致性重新设计表示”。本文属于显式辐射原语这一脉络,但关注点不是新增物理分支,而是在极稀疏 CT 中显式控制高斯容量分配与结构冗余。

3. 方法

图 1 回答的是 pipeline 层的问题:为什么本文能够在极稀疏 CT 上优于现有方法。其核心不在于继续给 densification backbone 叠加一个辅助分支,而在于把优化顺序从“持续密化后再补救”改写为一条 coarse-to-fine allocation 链路,即“先粗分配、再回收、再细化”。本节则转到方法层,说明这一 pipeline 如何具体实例化为 SPS、GAP 与 ADM,并嵌入 R²-Gaussian 的辐射高斯主干。

3.1. 问题定义

设极稀疏视角观测集合为 $\mathcal{P} = \{(I_v, \pi_v)\}_{v=1}^V$, 其中 I_v 表示第 v 个 X 射线投影, π_v 表示对应成像几何。给定由这些观测得到的 FDK 粗重建体 V_{FDK} , 本文目标是在病例级优化设定下学习一个显式辐射高斯表示,用于从少量观测投影合成未观测角度下的目标投影图像。虽然这一任务与体密度恢复天然耦合,但本文的主要优化目标仍是投影域的新视图合成质量。

3.2. 3DGS 与 X-ray 渲染基础

我们将场景表示为高斯集合 $\mathcal{G} = \{g_i\}_{i=1}^N$, 其中每个高斯写作

$$g_i = (\mathbf{p}_i, \Sigma_i, \rho_i, \mathbf{c}_i), \quad (1)$$

分别表示中心、协方差、密度与外观/辐射参数。对于任一视角 π_v , R²-Gaussian 风格的辐射渲染可记为

$$\hat{I}_v = \mathcal{R}(\mathcal{G}; \pi_v). \quad (2)$$

除本文新增的 SPS、GAP 与 ADM 外,其余辐射栅格化、密化与可微体素化设置均遵循 R²-Gaussian [ZLC*24]。在这一基线中,高斯通常根据投影误差梯度执行复制/分裂式密化;这一机制在自然图像场景中能够有效补足表面覆盖,但在 CT 场景中更容易把表示容量持续推向高梯度解剖边界,这也正是本文后续三个模块要处理的核心问题。

3.3. 总体框架

如图 2 所示, CareX-GS 将 introduction 中的 pipeline-level 容量重分配具体实例化为三个顺序模

块，并插入 R^2 -Gaussian 的显式辐射高斯主干。SPS 在初始化阶段利用 FDK 粗重建将高斯播种到更相关的解剖区域；GAP 在密化之后周期性回收局部冗余高斯，避免高梯度边界反复占据容量；ADM 则在后续优化中根据位置相关上下文细化保留高斯的密度分布。因而，本文并不重新设计 X 射线成像物理，而是在同一条 X-ray 3DGS 优化链路中，依次完成“放对位置、回收冗余、细化密度”的容量重分配。

3.4. Spatial Prior Seeding (SPS)

SPS 基于 FDK 粗重建得到的解剖密度先验在解剖相关区域初始化高斯原语。初始化会直接影响后续优化轨迹，而标准 3DGS 常用的均匀采样或 SfM 点云初始化均不适合 CT 场景：前者无法区分空气、软组织与骨骼的解剖重要性，后者则由于 X 射线投影中的灰度重叠与低纹理特征难以稳定工作 [CLW*24]。这里的“先验”并非抽象的空间偏置，而是由 FDK 粗重建提供的粗粒度解剖密度线索，它虽然不足以直接完成高质量重建，却能够先把初始高斯锚定到更可能承载有效结构的位置。因此，我们使用 FDK 重建产生的粗体密度图 V_{FDK} 作为初始化依据，并在离散体素网格 Ω 上定义密度加权采样分布：

$$p(\mathbf{x}) = \frac{(\max(V_{\text{FDK}}(\mathbf{x}), \epsilon))^\gamma}{\sum_{\mathbf{x}' \in \Omega} (\max(V_{\text{FDK}}(\mathbf{x}'), \epsilon))^\gamma}, \quad (3)$$

其中 ϵ 用于避免背景区域出现零概率， γ 控制采样集中度。

仅靠密度加权会使高斯过度聚集在亮度最高的骨性结构附近，因此我们采用均匀分布与先验分布的混合采样：

$$q(\mathbf{x}) = \alpha \frac{1}{|\Omega|} + (1 - \alpha)p(\mathbf{x}), \quad \mathbf{x} \in \Omega, \quad (4)$$

并从 $q(\mathbf{x})$ 独立采样 M 个初始中心 $\{\mathbf{x}_m\}_{m=1}^M$ ，其中 M 为初始化高斯数。这样既能保证整体覆盖，又能让更多高斯优先分配给解剖复杂区域。采样位置确定后，我们将 FDK 值作为初始密度，并根据局部采样密度设定尺度参数，最终得到 50K 个初始高斯。本文中， α 与 γ 通过小范围搜索确定后保持固定，以避免为不同实验场景额外引入手工调参。

3.5. Geometry-aware Pruning (GAP)

GAP 根据空间邻近度与梯度活跃性周期性移除局部冗余高斯。在 CT 场景中，基于梯度的密化往往会在骨组织与软组织边界持续复制高斯，因为这些区域具有更大的投影误差梯度。然而，高梯度并不总是意味着覆盖不足，也可能只是同一条解剖边界被多个相邻高斯反复表达。因此，GAP 不沿用 FSGS 面向稀疏区域补点的思路 [ZFJW24]，而是转而在世界坐标系中显式度量局部拥挤程度，并将其作为一次面向过密区域的反向冗余回收。

具体来说，对每个高斯 G_i ，记 $\mathcal{N}_K(i)$ 为除 i 自身外的 K 个最近邻索引集合，我们计算其与这些邻居的平均欧氏距离作为邻近度评分：

$$s_i = \frac{1}{K} \sum_{j \in \mathcal{N}_K(i)} \|\mathbf{p}_i - \mathbf{p}_j\|_2. \quad (5)$$

当 s_i 低于阈值 τ 时，说明该高斯处于过度聚集区域。为了避免误删仍在有效学习的高斯，我们再引入梯度活跃性过滤。记 $\bar{g}_i$ 为该高斯在当前密化周期内累积的位置梯度 L_1 统计量，并定义保留掩码 $m_i \in \{0, 1\}$ 为

$$m_i = \begin{cases} 1, & s_i \geq \tau \vee \bar{g}_i \geq \delta, \\ 0, & \text{otherwise.} \end{cases} \quad (6)$$

其中 $m_i = 0$ 表示该高斯会在当前周期被视为冗余候选。实现上，GAP 不是替代 3DGS 原有的密化，而是作为其后的周期性回收步骤运行：先沿用原始复制/分裂式密化生成候选高斯，再用 m_i 过滤冗余点。最终，每轮最多剪除总高斯数的 β_{prune} ，并在第 $2K$ 到 $20K$ 次迭代间周期性触发。为避免剪枝后局部支撑突然变稀，我们仅对保留下来的新生成高斯执行协方差收缩：

$$\Sigma_i^{\text{new}} = \eta \Sigma_i, \quad 0 < \eta < 1. \quad (7)$$

GAP 通过抑制局部冗余高斯来正则化密化过程，从而避免高梯度边界持续占据表示容量。

3.6. Adaptive Density Modulation (ADM)

ADM 预测位置相关的密度偏移，以细化保留高斯的密度分布。即便经过更合理的初始化与冗余控制，不




Figure 2: CareX-GS 的总体流程。给定极稀疏 CT 投影与 FDK 粗重建, SPS 负责空间先验播种, GAP 负责几何冗余回收, ADM 负责位置相关的密度修正, 最终生成目标新视图 X 射线投影。




Figure 3: SPS 模块示意。利用 FDK 粗重建引导密度加权采样, 使更多初始高斯落在解剖相关区域, 并保留少量均匀补偿采样维持全局覆盖。

同解剖区域的密度更新规律仍然存在显著差异：骨组织通常对应更高衰减系数，肺部空气区域应保持更低密度，而软组织则需要平滑过渡。若所有高斯都共享相同的逐点梯度更新规则，模型难以表达这种空间异质性。为此，我们用 K-Planes 对高斯中心位置进行编码，并通过轻量解码器仅预测密度相关的偏移与置信门控，而不改写高斯的中心、协方差或其他属性。ADM 的作用是细化局部密度分布，而非单独决定整体性能上限。




Figure 4: GAP 模块示意。先依据世界坐标邻近度识别局部过度聚集区域，再结合梯度活跃性过滤，仅删除学习价值较低的冗余高斯。

需要强调的是，ADM 虽然包含 MLP，但它并不是一个离线预训练的 prediction head，也不依赖额外的密度标签监督。K-Planes 特征与双头 MLP 参数都只在当前病例优化过程中更新，并通过主渲染损失端到端反向传播；因此，ADM 本质上是一个 on-the-fly 的在线联合优化分支，用来在主干训练过程中自适应地放大或抑制不同区域的密度响应。

给定位置 $\mathbf{x}$ ，我们先将其投影到三组正交平面的归一化二维坐标 $\Pi_{uv}(\mathbf{x})$ ，再从对应特征图中双线性

采样:

$$f_{uv}(\mathbf{x}) = \mathcal{B}(P_{uv}, \Pi_{uv}(\mathbf{x})), \quad uv \in \{xy, xz, yz\}, \quad (8)$$

$$F(\mathbf{x}) = \text{concat}(f_{xy}(\mathbf{x}), f_{xz}(\mathbf{x}), f_{yz}(\mathbf{x})), \quad (9)$$

其中 $\mathcal{B}(\cdot)$ 表示双线性采样, P_{xy} 、 P_{xz} 与 P_{yz} 分别对应三张正交特征平面, $\text{concat}(\cdot)$ 表示按通道拼接。这种 K-Planes 编码最早被用于显式时空辐射场建模, 能够以较低成本提供连续空间上下文 [FYT*23]。在此基础上, 我们用双头 MLP 输出密度偏移 $o(\mathbf{x})$ 和置信门控 $c(\mathbf{x})$:

$$(o(\mathbf{x}), c(\mathbf{x})) = h(F(\mathbf{x})). \quad (10)$$

随后将偏移做 batch 均值中心化, 并结合视角相关缩放写为

$$\tilde{o}(\mathbf{x}) = \beta(t) s_{\text{view}} r_{\text{max}} c(\mathbf{x}) \cdot (o(\mathbf{x}) - \bar{o}), \quad (11)$$

其中 $\bar{o}$ 为当前 batch 的均值偏移, r_{max} 为最大调制幅度, s_{view} 表示随输入视角数变化的缩放系数。为避免调制在训练早期干扰基础几何收敛, 我们将 $\beta(t)$ 设为预热-保持-衰减调度:

$$\beta(t) = \begin{cases} \frac{t}{t_w}, & 0 \leq t < t_w, \\ 1, & t_w \leq t < t_h, \\ \exp\left(-\frac{t-t_h}{\tau}\right), & t \geq t_h. \end{cases} \quad (12)$$

最终密度写成

$$\rho_{\text{final}}(\mathbf{x}) = \rho_{\text{base}}(\mathbf{x}) \cdot (1 + \tilde{o}(\mathbf{x})). \quad (13)$$

这样, ADM 学到的不是全局性的密度抬升, 而是围绕空间上下文的相对修正, 从而更符合 CT 体数据中“区域异质、局部连续”的分布特征。

3.7. 训练损失函数

CareX-GS 的三个模块与 R²-Gaussian 的辐射渲染主干共同构成端到端训练流程。训练时, 我们对观测视角上的重投影结果进行监督, 整体损失写为

$$\mathcal{L} = \mathcal{L}_1 + \lambda_{\text{dssim}} \mathcal{L}_{\text{dssim}} + \lambda_{3\text{DTV}} \mathcal{L}_{3\text{DTV}} + \lambda_{\text{pTV}} \mathcal{L}_{\text{pTV}}, \quad (14)$$




Figure 5: ADM 模块示意。利用 K-Planes 提供连续空间上下文, 并预测位置相关的密度偏移与置信门控, 实现解剖区域相关的密度调制。

其中

$$\mathcal{L}_1 = \frac{1}{V} \sum_{v=1}^V \|I_v - \hat{I}_v\|_1, \quad (15)$$

$$\mathcal{L}_{\text{dssim}} = \frac{1}{V} \sum_{v=1}^V \text{DSSIM}(I_v, \hat{I}_v), \quad (16)$$

$$\mathcal{L}_{3\text{DTV}} = \sum_{i=1}^N \sum_{d \in \{x,y,z\}} |\nabla_d \rho_i|, \quad (17)$$

$$\mathcal{L}_{\text{pTV}} = \sum_{p \in \{xy, xz, yz\}} \omega_p(t) \text{TV}(P_p). \quad (18)$$

其中, $\omega_p(t)$ 为第 p 张特征平面的时变正则权重, $\mathcal{L}_1$ 与 $\mathcal{L}_{\text{dssim}}$ 共同约束投影重建质量, $\mathcal{L}_{3\text{DTV}}$ 用于约束体密度的空间平滑性, 而 $\mathcal{L}_{\text{pTV}}$ 则对 K-Planes 特征施加平面总变分正则。训练时, ADM 的平面特征与 MLP 参数和主干高斯参数一起通过上述损失联合更新, 因此其密度调制是在线学习到的, 而非预先固定。由于 SPS 只改变初始化、GAP 仅在训练中周期性触发、ADM 只对密度进行轻量调制, 推理阶段的基本 X 射线渲染流程保持不变, 额外开销主要发生在训练期间。

4. 实验

4.1. 实验设置

数据与任务设定。 我们采用 X-Gaussian 官方仓库发布的 processed datasets。其五个 paper scenes 中,

Chest 来自 LIDC-IDRI, Head、Abdomen、Foot 与 Pancreas 来自 open scientific visualization dataset; 数据包沿用了 NAF/X-Gaussian 系列工作的投影生成与预处理协议, 并整理为统一的数据格式。本文在该公开数据基础上进一步抽取每个病例仅保留 2/3/4 个输入投影的子集, 并将这一 2-4 view 的病例级优化设定称为极稀疏视角; 模型仅使用这些观测投影进行训练, 在未观测角度上评估新视图投影质量。

对比方法。我们选取 5 个与本文最相关的 3DGS 基线: DNGaussian [LZB*24]、CoR-GS [ZLY*24]、FSGS [ZFJW24]、X-Gaussian [CLW*24] 以及 R²-Gaussian [ZLC*24]。其中前三者分别代表自然图像 sparse-view 3DGS 中较典型的几何正则、协同抑制和补点扩张路线, 后两者则提供了面向 X 射线与 CT 场景的直接辐射式对比基础。

评价指标。我们报告 PSNR 与 SSIM。按照 X-Gaussian 官方评估脚本的实现, 先将渲染结果与真值投影统一归一化到 $[0, 1]$, 再对每个测试投影逐幅计算指标, 并对同一场景的全部测试视角取平均。PSNR 按 $20 \log_{10}(1/\sqrt{\text{MSE}})$ 计算, 其中 MSE 为整幅投影上的均方误差; SSIM 使用 11×11 Gaussian window、 $\sigma = 1.5$, 并采用 $C_1 = 0.01^2$ 、 $C_2 = 0.03^2$ 的标准设置。

实现细节。SPS 使用 $\alpha = 0.2$ 、 $\gamma = 1.0$ 与 50K 初始高斯; GAP 采用 $K = 5$ 邻居、阈值 $\tau = 0.015$ 、最大剪枝比 $\beta_{\text{prune}} = 0.02$ 、梯度阈值 $\delta = 0.0002$; ADM 采用分辨率 64 的 K-Planes、特征维度 32, 并在 15K 次迭代后启动。所有模型训练 30K 次迭代。

4.2. 主结果

表 1 汇报了五个器官、全部极稀疏协议上的 PSNR 主结果。CareX-GS 在各协议的平均结果上均排名第一, 并在 Chest、Head、Abdomen 与 Pancreas 上保持稳定领先; 相对当前最强基线 R²-Gaussian, 平均增益在各协议上始终为正, 代表性协议下可达到 0.39 dB。这说明本文的容量重分配不仅改善了高对比边界, 也提升了混合软组织区域的投影建模质量。与此同时, 在最极端的 2-view 设定下, Foot 与 Pancreas

等场景的提升仍然有限, 说明当观测约束进一步削弱时, 单靠更合理的初始化与密度重分配仍无法完全替代真实投影信息, 这也与该任务的病态性相一致。

最具挑战的结果主要出现在 Foot 与 Pancreas, 说明当器官结构更复杂、投影约束更弱时, FDK 空间先验与局部密度修正仍难以完全替代真实观测。

SSIM 与 PSNR 保持一致趋势。以代表性协议的五器官平均为例, CareX-GS 的 SSIM 从 R²-Gaussian 的 0.9025 提升到 0.9057, 并在 Chest、Abdomen、Pancreas 与 Foot 上保持一致改进。这说明本文收益并不依赖单一像素误差指标, 而在结构相似性上同样成立; 全量 SSIM 数值放在补充材料中。

图 6 展示了代表性极稀疏设定下的主定性对比。相较于面向自然图像的 sparse-view 3DGS 基线, R²-Gaussian 与 CareX-GS 均能恢复更符合 X 射线成像特性的整体解剖轮廓; 进一步与 R²-Gaussian 相比, CareX-GS 在 Chest 和 Pancreas 等场景中减少了背景噪声、边界扩散与局部外溢。

图 7 左侧放大了肋骨与颅骨边界附近的局部区域, CareX-GS 在这些区域保留了更平滑的组织过渡并减少了边界伪影。右侧的跨视角一致性对比表明, CareX-GS 在不同目标角度下能够维持更稳定的形态结构。

4.3. 消融实验

图 8 汇报了代表性极稀疏设定下的模块消融。仅加入 GAP 就可将平均 PSNR 从 27.80 dB 提升到 28.22 dB, 说明几何感知剪枝已经完成了最关键的容量重分配; SPS 单独带来 0.21 dB 增益, ADM 单独带来 0.11 dB 增益, 而 SPS+ADM 的组合可稳定达到 28.09 dB。这些结果表明, GAP 是主要性能来源, 而 SPS 与 ADM 分别承担更好的初始化与更平滑的局部密度细化。

Table 1: 五个器官在不同极稀疏协议下的 *PSNR* 对比 (*dB*, $\uparrow$)。最优加粗，次优下划线。

Method	Chest			Head			Abdomen		
	2v	3v	4v	2v	3v	4v	2v	3v	4v
DN-Gaussian	14.30	16.02	15.76	15.72	18.04	16.24	19.33	23.51	24.72
CoR-GS	14.96	18.55	20.29	16.24	20.36	23.40	18.50	22.45	23.03
FSGS	17.86	19.99	21.03	19.43	21.53	24.91	18.75	23.34	23.63
X-Gaussian	17.79	20.29	20.90	19.62	21.52	24.46	18.93	23.54	23.85
R ² -Gaussian	<u>21.05</u>	<u>26.22</u>	<u>25.47</u>	<u>23.54</u>	<u>26.60</u>	28.66	<u>24.85</u>	<u>29.26</u>	<u>30.56</u>
CareX-GS	21.26	26.81	25.83	23.63	26.63	<u>28.52</u>	24.97	29.73	30.89

Method	Foot			Pancreas			Avg		
	2v	3v	4v	2v	3v	4v	2v	3v	4v
DN-Gaussian	20.17	23.51	19.33	16.15	22.43	25.47	17.13	20.70	20.30
CoR-GS	20.17	25.53	26.83	16.15	23.25	23.96	17.20	22.03	23.50
FSGS	<u>22.17</u>	25.37	27.08	<u>23.03</u>	25.27	26.22	20.25	23.10	24.57
X-Gaussian	22.34	25.48	26.92	23.21	25.12	25.55	20.38	23.19	24.34
R ² -Gaussian	19.39	<u>28.48</u>	30.04	17.83	<u>28.61</u>	30.90	<u>21.33</u>	<u>27.83</u>	<u>29.13</u>
CareX-GS	19.55	28.49	<u>29.86</u>	17.80	29.43	30.90	21.44	28.22	29.20


**Figure 8:** 代表性极稀疏设定下的模块消融柱状图。所有数值均为五个器官的平均 *PSNR*；金色边框标出最优配置。

图 9 展示了模块递进带来的可视化差异与空间结构变化。上半部分中，+GAP 已经减少了边界附近的主要高亮伪影，完整模型则进一步改善局部灰度过渡；下半部分显示，SPS 将初始化从均匀分布调整到更贴合粗重建的区域，GAP 进一步移除外围冗余

高斯，最终 CareX-GS 在更紧凑的空间支撑上完成渲染。这些现象与柱状图中的数值趋势相一致，说明本文收益主要来自对高斯表示容量的重新分配，而非单纯增加原语数量；也因此 +GAP 与 Full 在 *PSNR* 上接近，而完整模型进一步改善了局部灰度过渡与训练稳定性。

4.4. 超参数实验与效率分析

图 10 给出了关键超参数在代表性协议上的平均 *PSNR* 扫描结果。整体上，SPS 的均匀混合比例采用 $\alpha = 0.2$ 最稳健，说明在极稀疏 CT 中保留一定全局覆盖即可，过大的均匀比例会稀释结构先验；GAP 在 $\tau = 0.015$ 与 $\beta_{\text{prune}} = 2\%$ 时取得最佳结果，表明冗余回收需要保持“足够积极但不过度”的强度；ADM 的 warm-up 采用 15K 次迭代最好，说明密度调制更适合在基础几何基本收敛后介入。

图 11 从效率与优化过程两个角度汇报了结果。左图显示，CareX-GS 在接近 R²-Gaussian 推理速




Figure 6: 代表性极稀疏设定下的主定性对比。每一行对应一个器官场景，最左列给出训练输入投影，其余列展示同一目标视角下的真值与各方法输出。与面向自然图像的 *sparse-view 3DGS* 基线相比， R^2 -Gaussian 与 *CareX-GS* 更符合 X 射线结构分布，而 *CareX-GS* 在胸腔背景、头部轮廓和胰腺区域进一步压低了伪影与边界扩散。

度的同时位于更优的 PSNR-FPS 权衡前沿；右图表明，无论按迭代次数还是按 wall-clock time 统计，*CareX-GS* 都能更早达到更高的 PSNR 平台。按当前实现，SPS/GAP/ADM 带来的额外训练开销控制在 10% 以内，而推理端基本保持同一量级，说明性能提升未引入显著额外推理开销。




Figure 7: 局部细节与跨视角一致性分析。上：两组放大 ROI，对比肋骨/颅骨边界附近的局部结构与软组织过渡。下：同一病例在三个目标角度下的结果，*CareX-GS* 相比 *R²-Gaussian* 保持了更稳定的跨视角形态，并减少了角度特异性伪影。




Figure 9: 结构冗余机制的可视化分析。上：代表性极稀疏设定下的渐进式消融可视化，展示 *Baseline*、*+GAP* 与 *Full* 在两组 *Chest* 案例上的预测结果及残差图。仅加入 *GAP* 时已能去除主要伪影，完整模型则进一步稳定局部灰度过渡。下：高斯空间分布的逐步收紧过程。从均匀初始化到 *SPS* 引导初始化，再到 *GAP* 剪枝与最终 *CareX-GS*，高斯支撑逐步贴合有效结构区域。




Figure 10: 关键超参数的折线扫描结果。所有曲线均基于代表性极稀疏协议下的五器官平均 $PSNR$ ，其他参数保持默认设置。




Figure 11: 效率与收敛分析。左：不同方法的 $PSNR$ – FPS 权衡，圆点大小表示最终 *Gaussian* 数量。右：CareX-GS 与 R^2 -Gaussian 在代表性 Chest 场景上的 $PSNR$ 收敛曲线，分别按迭代次数和 wall-clock time 统计。

5. 结论

本文提出 CareX-GS, 一个面向极稀疏 CT 新视图合成的 X-ray Gaussian Splatting 容量重分配框架。我们的核心判断是: 在穿透式 X 射线成像下, 问题往往不只是高斯数量不足, 更在于传统密化把容量错误集中到了高对比边界。围绕这一判断, SPS、GAP 和 ADM 分别在初始化、冗余回收与局部密度建模三个阶段协同重分配表示容量, 并在五个器官、全部极稀疏协议上的主结果、消融与超参数实验中验证了其对于 PSNR 与 SSIM 的稳定提升; 未来我们将继续探索更强的器官自适应先验, 并把该框架扩展到 cone-beam 与动态 CT 场景。

References

- [AK84] ANDERSEN, A. H. and KAK, A. C. “Simultaneous Algebraic Reconstruction Technique (SART): A Superior Implementation of the ART Algorithm”. *Ultrasonic Imaging* 6.1 (1984), 81–94 1, 4.
- [CLTS24] CHARATAN, DAVID, LI, SIZHE LESTER, TAGLIASACCHI, ANDREA, and SITZMANN, VINCENT. “pixelSplat: 3D Gaussian Splats from Image Pairs for Scalable Generalizable 3D Reconstruction”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024, 19457–19467 3.
- [CLW*24] CAI, YUANHAO, LIANG, YIXUN, WANG, JIAHAO, et al. “Radiative Gaussian Splatting for Efficient X-ray Novel View Synthesis”. *European Conference on Computer Vision (ECCV)*. 2024 2, 4, 5, 8.
- [CW24] CHEN, GUIKUN and WANG, WENGUAN. “A Survey on 3D Gaussian Splatting”. *arXiv preprint arXiv:2401.03890* (2024) 2.
- [CWY*24] CAI, YUANHAO, WANG, JIAHAO, YUILLE, ALAN, et al. “Structure-Aware Sparse-View X-ray 3D Reconstruction”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024, 11174–11183 4.
- [CXZ*24] CHEN, YUEDONG, XU, HAOFEI, ZHENG, CHUANXIA, et al. “MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images”. *European Conference on Computer Vision (ECCV)*. 2024 3.
- [FDK84] FELDKAMP, L. A., DAVIS, L. C., and KRESS, J. W. “Practical Cone-Beam Algorithm”. *Journal of the Optical Society of America A* 1.6 (1984), 612–619 1, 4.
- [FYT*23] FRIDOVICH-KEIL, SARA, YU, GIANG, TANCIK, MATTHEW, et al. “K-Planes: Explicit Radiance Fields in Space, Time, and Appearance”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2023 7.
- [GL24] GUÉDON, ANTOINE and LEPETIT, VINCENT. “SuGaR: Surface-Aligned Gaussian Splatting for Efficient 3D Mesh Reconstruction and High-Quality Mesh Rendering”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [KKLD23] KERBL, BERNHARD, KOPANAS, GEORGIOS, LEIMKÜHLER, THOMAS, and DRETTAKIS, GEORGE. “3D Gaussian Splatting for Real-Time Radiance Field Rendering”. *ACM Transactions on Graphics* 42.4 (2023), 1–14 2.
- [KYW25] KONG, HANYANG, YANG, XINGYI, and WANG, XINCHAO. “Generative Sparse-View Gaussian Splatting”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025, 26745–26755 3.
- [LFL*25] LIU, ZHENTAO, FANG, YU, LI, CHANGJIAN, et al. “Geometry-Aware Attenuation Learning for Sparse-View CBCT Reconstruction”. *IEEE Transactions on Medical Imaging* 44.2 (2025), 1083–1097 4.
- [LFY*25] LIU, YIFAN, FAN, KEYU, YU, WEIHAO, et al. “MonoSplat: Generalizable 3D Gaussian Splatting from Monocular Depth Foundation Models”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025 3.
- [LYX*24] LU, TAO, YU, MULIN, XU, LINNING, et al. “Scaffold-GS: Structured 3D Gaussians for View-Adaptive Rendering”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [LZB*24] LI, JIAHE, ZHANG, JIAWEI, BAI, XIAO, et al. “DNGaussian: Optimizing Sparse-View 3D Gaussian Radiance Fields with Global-Local Depth Normalization”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2, 3, 8.
- [NMKW24] NAVANEET, K., MEIBODI, KOOSHK, KOIKE-AKINO, TOSHIKI, and WANG, YIBO. “Compact 3D Gaussian Splatting for Sparse View Rendering”. *arXiv preprint arXiv:2311.18159* (2024) 2.
- [PRK25] PARK, HYUNWOO, RYU, GUN, and KIM, WONJUN. “DropGaussian: Structural Regularization for Sparse-view Gaussian Splatting”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025, 21600–21609 3.
- [RNSZ24] RÖSSLE, BARBARA, NIESSNER, MATTHIAS, SEIDEL, HANS-PETER, and ZOLLHÖFER, MICHAEL. “Densification Strategies for 3D Gaussian Splatting”. *arXiv preprint arXiv:2401.17151* (2024) 2.

- [WLG*25] WU, SHAKAI, LU, YUXIANG, GUO, YAPAN, et al. “Discretized Gaussian Representation for Tomographic Reconstruction”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2025, 25073–25082 4.
- [WRW*24] WU, ZIYI, REN, JIAWEI, WANG, XIAO, et al. “4D Gaussian Splatting for Real-Time Dynamic Scene Rendering”. *arXiv preprint arXiv:2310.08528* (2024) 2.
- [WTW*25] WANG, FEIRAN, TAO, JIACHEN, WU, JUNYI, et al. “X-Field: A Physically Informed Representation for 3D X-ray Reconstruction”. *Advances in Neural Information Processing Systems (NeurIPS)*. 2025 4.
- [WYD08] WANG, GE, YU, HENGYONG, and DE MAN, BRUNO. “An Outlook on X-Ray CT Research and Development”. *Medical Physics* 35.3 (2008), 1051–1064 1.
- [XLG*24] XU, LINNING, LI, JIAMING, GAO, JINGKAI, et al. “Grid-Guided Gaussian Splatting for Large-Scale Outdoor Scene Rendering”. *arXiv preprint arXiv:2403.11852* (2024) 2.
- [XPW*25] XU, HAOFEI, PENG, SONGYOU, WANG, FANGJINHUA, et al. “DepthSplat: Connecting Gaussian Splatting and Depth”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025 3.
- [YCH*24] YU, ZEHAO, CHEN, ANPEI, HUANG, BINBIN, et al. “Mip-Splatting: Alias-free 3D Gaussian Splatting”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [YCZ*25] YU, WEIHAO, CAI, YUANHAO, ZHA, RUYI, et al. “X²-Gaussian: 4D Radiative Gaussian Splatting for Continuous-Time Tomographic Reconstruction”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2025 4.
- [YGZ*24] YANG, ZEYU, GAO, BINGLIANG, ZHOU, YIBO, et al. “Deformable 3D Gaussian Splatting for High-Fidelity Monocular Dynamic Scene Reconstruction”. *arXiv preprint arXiv:2309.13101* (2024) 2.
- [YMS*25] YULUO, YIKUANG, MA, YUE, SHEN, KUANG, et al. “GR-Gaussian: Graph-Based Radiative Gaussian Splatting for Sparse-View Tomographic Reconstruction”. *arXiv preprint arXiv:2508.02408* (2025) 4.
- [ZFJW24] ZHU, ZEHAO, FAN, ZHIWEN, JIANG, YIFAN, and WANG, ZHANGYANG. “FSGS: Real-Time Few-Shot View Synthesis Using Gaussian Splatting”. *European Conference on Computer Vision (ECCV)*. 2024 2, 3, 5, 8.
- [ZLC*24] ZHA, RUYI, LIN, TAO JUN, CAI, YUANHAO, et al. “R²-Gaussian: Rectifying Radiative Gaussian Splatting for Tomographic Reconstruction”. *Advances in Neural Information Processing Systems (NeurIPS)*. 2024 2, 4, 8.
- [ZLY*24] ZHANG, JIAWEI, LI, JIAHE, YU, XIAOHAN, et al. “CoR-GS: Sparse-View 3D Gaussian Splatting via Co-Regularization”. *European Conference on Computer Vision (ECCV)*. 2024 2, 3, 8.