

SPAGS: Spatially-Aware Gaussian Splatting via Redundancy Control for Sparse-View CT Novel View Synthesis

Abstract

稀疏视角 CT 新视图合成旨在从少量 X 射线投影生成未观测角度的投影图像，对低剂量扫描和快速成像具有重要意义。近期基于 *3D Gaussian Splatting* 的方法显著提升了 X-ray/CT 场景中的表示效率，但在极少视角条件下，它们大多仍将性能退化归因于覆盖不足、优化不稳或几何误差，并相应地继续 *densify* 或引入额外正则。我们认为，这一解释并不完全适用于 CT：由于体密度空间是连续占据的，高梯度解剖边界会反复吸引高斯复制，使表示容量被局部过度消耗，而组织内部与低对比区域反而得不到充分建模。基于这一观察，我们提出 SPAGS，一个围绕表示容量重分配的空间感知高斯泼溅框架，其中 SPS 利用 FDK 粗重建将高斯初始化到更相关的解剖区域，GAP 在世界坐标中识别并回收局部冗余高斯，ADM 则对保留下来的高斯施加位置相关的密度修正。在 5 个器官、2/3/4 视角的实验中，SPAGS 在所有对比方法中取得最优平均 PSNR，并分别在 2/3/4-view 设定下达到 21.44/28.22/29.20 dB；在最关键的 3-view 设定下，相比当前最强基线 R^2 -Gaussian 提升 0.39 dB，补充 SSIM 指标也保持一致领先趋势。消融实验进一步验证了方法有效性：仅加入 GAP 就能带来 +0.42 dB 的增益并达到完整模型水平，而 SPS 与 ADM 主要改善初始化质量和局部修正稳定性。结果表明，对于 *sparse-view CT*，更有效的方向不是单纯增加高斯数量，而是显式控制结构冗余并重新分配表示容量。

1. 引言

稀疏视角条件下的 CT 新视图合成 (novel view synthesis, NVS) 旨在从少量 X 射线投影合成未观测角度的投影图像；由于 X 射线观测由体密度积分决定，这一任务与体重建天然耦合，但本文的主要评价目标仍是新视角投影质量。该任务具有明确的应用价值：减少采样视角可以降低辐射剂量、缩短扫描时间并减轻设备负担；但视角稀缺也会显著削弱几何约

束，使病例级优化更容易陷入欠定状态。与自然图像中的新视图合成不同，X 射线成像遵循穿透式辐射传输，像素观测是整条射线路径上衰减累积的结果，因此这一任务对初始化位置、空间分布和密度建模都更加敏感 [FDK84; AK84; WYD08]。

围绕 *sparse-view setting*，现有 3DGS 方法大多从三个方向解释性能下降：覆盖不足、优化不稳或几何退化。FSGS 倾向于通过补点扩张高斯覆盖范

国 [ZFJW24]; CoR-GS 通过双场 disagreement 抑制不一致几何 [ZLY*24]; DNGaussian 借助深度先验直接修复稀疏视角下的几何错误 [LZB*24]。在 X-ray/CT 场景中, X-Gaussian 与 R^2 -Gaussian 又分别补足了辐射高斯表示和积分偏差修正 [CLW*24; ZLC*24]。这些工作共同推动了 CT-3DGS 从“能否渲染”走向“能否重建”,但它们在优化层面仍保留了一个近似共享的默认假设:当结果变差时,主要问题通常是高斯不够、约束不够,或者几何还不够准。

我们的观察是,这个假设并不完全适用于稀疏视角 CT。CT 体数据并不是由少量可见表面和大面积空背景组成,而是一个被不同组织密度连续占据的体空间。骨组织与软组织边界往往拥有最强的梯度信号,于是传统“梯度越大越 densify”的策略会持续在边界附近复制高斯,使表示容量不断被局部高梯度区域吞噬;与此同时,组织内部和低对比区域却得不到足够稳定的建模。也就是说,在 sparse-view CT 中,限制优化的往往不是“高斯还不够多”,而是“高斯被持续堆在了不该堆的地方”。相比继续补点,我们更需要显式控制结构冗余,并把表示容量重新分配到真正有助于成像一致性的空间位置。

基于这一判断,我们提出 SPAGS,一个面向稀疏视角 CT 新视图合成的结构冗余控制框架。它不重新定义 X 射线成像物理,也不引入额外的双场分支,而是在同一条 3DGS 优化链路上重新安排表示容量的分配方式。具体而言,SPS (Spatial Prior Seeding) 利用 FDK 粗重建提供的空间先验,把初始高斯放到更相关的解剖区域;GAP (Geometry-aware Pruning) 在世界坐标中联合邻近度与梯度活跃性回收局部冗余高斯,是全文最主要的性能驱动;ADM (Adaptive Density Modulation) 则作为轻量辅助模块,对保留下来的高斯做位置相关的密度修正,以平滑局部灰度过渡。

因此,SPAGS 与现有五个核心对比方法的差异,不在于再次强化补点、深度约束或物理建模,而在于提出了一个更贴合 CT 体空间分布规律的优化观点:当观察视角极少时,3DGS 的关键不是继续增加表示容量,而是避免容量被高梯度边界错误吸走,并在初

始化、回收和调制三个阶段把高斯放到更合适的位置。图 1 对这一差异做了一个压缩总览。

我们的贡献可以概括为三点:

- 我们重新界定了稀疏视角 CT 中的核心优化瓶颈,指出限制 3DGS 性能的往往不是单纯覆盖不足,而是高斯在高梯度边界被持续放大后形成的结构冗余。
- 我们围绕这一判断提出 SPAGS: SPS 负责把高斯初始化到更相关的解剖区域, GAP 负责在世界坐标中回收局部冗余高斯, ADM 则作为轻量辅助模块学习位置相关的密度修正。
- 我们在 5 个器官、2/3/4 视角设置下进行了系统评估。结果显示, SPAGS 在核心 3-view 设定下相对 R^2 -Gaussian 提升 0.39 dB 平均 PSNR; 消融进一步表明, GAP 的冗余控制是主要性能来源,而 SPS 与 ADM 主要改善初始化质量和局部修正稳定性。

在 5 个器官、2/3/4 视角的设置下, SPAGS 在核心 3-view 设定中达到 28.22 dB 平均 PSNR, 相比 R^2 -Gaussian 提升 0.39 dB; 与此同时, 2-view 场景中的增益明显更不稳定, 4-view 场景中的方法差距则自然收缩。这个结果分布与我们的判断一致: SPAGS 最有效的区间不是“任何稀疏条件”, 而是信息仍然紧张、但表示容量重分配仍能改变优化轨迹的中等稀疏区间。对这一工作而言, 最关键的结论并不是“我们又提升了一点分数”, 而是 sparse-view CT 更需要结构冗余控制, 而不是无差别地继续补点。

2. 相关工作

2.1. 稀疏视角 3D Gaussian Splatting

3D Gaussian Splatting 通过一组三维各向异性高斯显式表示场景, 并依赖可微分栅格化实现高效渲染, 在效率与质量之间取得了优于传统 NeRF 的平衡 [KKLD23]。自 2023 年提出以来, 围绕 3DGS 的工作迅速扩展到结构化表示、抗锯齿渲染、显式网格提取、动态时空建模与紧凑表示压缩等方向 [CW24; LYX*24; YCH*24; GL24; WRW*24;




Figure 1: 三类代表性 3DGS 路线的核心差异。主流 *sparse-view 3DGS* 更强调补点扩张、双场协同或深度约束；*CT/X-ray 3DGS* 主要解决辐射建模与积分偏差；*SPAGS* 则进一步把结构冗余控制显式引入初始化、回收与密度修正。

XLG*24; YGZ*24; NMKW24; RNSZ24]。但当输入视角显著减少时, 3DGS 容易暴露几何不稳定、密化失真与过拟合等问题, 因此“如何让 3DGS 适配 *sparse-view setting*”成为近一阶段的重要研究主线 [ZLY*24; LZB*24; ZFJW24]。

现有 *sparse-view 3DGS* 方法大致可以按其主导假设分成三类。第一类把问题理解为“初始化过稀导致覆盖不足”。FSGS 代表了这一思路：它在原始 3DGS 的 densification 流程上引入 proximity-guided Gaussian unpooling, 在已有高斯之间补点以提高表示密度, 并借助伪视角与单目深度先验抑制过拟合 [ZFJW24]。第二类把问题理解为“单场优化不稳定”。CoR-GS 并行优化两个随机初始化但共享监督的高斯场, 并把点位置与渲染结果的分歧当作无监督信号, 再据此设计 co-pruning 与 pseudo-view co-regularization [ZLY*24]。第三类则把问题归因于“几何恢复错误”。DNGaussian 引入 Hard/Soft Depth Regularization 和 Global-Local Depth Normalization, 用单目深度先验直接修复 *sparse-view* 条件下的几何退化 [LZB*24]。

这些方法都有效提升了自然图像场景下的

sparse-view 3DGS, 但它们共享一个重要前提：观察对象主要由可见表面主导, 核心困难在于表面覆盖不足、几何漂移或外部监督噪声。与这些基于优化的方法并行, 近期也有一批工作从前馈或泛化重建角度探索少视图高斯表示, 例如围绕深度协同与多视图先验的路线不断出现 [CWC*22; YPW23; WCLL23; XPW*25]。然而在 CT 场景中, 三维空间是被体密度连续占据的, 问题不再只是“表面没补够”或“几何不够准”, 而是高斯会在高对比边界被反复密化并形成结构冗余。我们的工作正是沿着这一区别, 重新界定 *sparse-view CT* 中真正需要优先控制的量。

2.2. X 射线新视图合成与 CT 断层重建

传统 CT 重建方法大体可以分为解析法与迭代法。以 FDK 为代表的解析方法依赖滤波反投影, 计算效率高, 但在稀疏视角下容易产生条纹伪影; SART 等迭代方法能够更稳健地引入先验约束, 但计算成本较高 [FDK84; AK84]。随着神经场方法的发展, 越来越多工作开始用坐标网络建模体密度场, 并通过自监督投影重建来进行病例级优化 [MST*21; ZZL*23; GWS*24; SGW*24]。这类方法在表示能力上表现强

劲,但体渲染依赖海量点采样,训练与推理开销通常难以满足高效应用场景的需求;Instant-NGP、TensorRF 等高效表示为此提供了重要启发 [MESK22; CXG*22]。

X-Gaussian 首次较为系统地把 3DGS 引入 X 射线新视图合成。由于 X 射线投影满足穿透式成像而非表面反射,该方法重新定义了 radiative Gaussian point cloud,并提出可微辐射栅格化与面向圆锥束扫描的 ACUI 初始化策略,从而显著提升了 X 射线 NVS 的训练与推理效率 [CLW*24]。R²-Gaussian 则进一步把问题推进到“直接体重建”的层面。该工作指出标准 3DGS 在从三维高斯投影到二维高斯的过程中存在积分偏差,这一偏差对普通图像渲染影响有限,但会严重破坏体密度恢复的一致性 [ZLC*24]。因此,R²-Gaussian 通过新的 radiative kernel、X 射线栅格化与可微体素化,把 3DGS 真正扩展为可用于稀疏视角断层重建的框架。换言之,X-Gaussian 主要回答“如何高效合成 X 射线投影”,而 R²-Gaussian 进一步回答“如何更准确地恢复体密度场”。

2025 年后,这条线开始明显分化。X-Field 不再沿用标准高斯体元,而是用具有材料衰减系数的三维椭球显式建模 X 射线穿透与累积衰减,并同时在 X-ray NVS 与 CT reconstruction 两个任务上报告了优势 [WTW*25];DGR 则转向直接体表示,用离散化 Gaussian functions 端到端重建体素网格,并强调体重建质量与运行效率的共同提升 [WLG*25]。与此同时,X²-Gaussian 将 radiative Gaussian 表示推进到连续时间 4D CT,而 GR-Gaussian 从图结构梯度建模角度进一步缓解极稀疏条件下的针状伪影,说明 CT-3DGS 已经开始从“能用”走向“更稳、更细”,并逐渐分化出物理表示改造、直接体重建和结构先验增强等不同路线 [YCZ*25; YMS*25]。

从与本文设定的关系看,X-Field 是最新工作中与我们最接近的一条线,因为它也同时覆盖 X-ray NVS 与 CT reconstruction;但其公开结果主要基于 10-view 训练、且数据组成与本文的 2/3/4-view 五器官设定并不完全一致,因此目前更适合作为同期强相关工作,而不是无需协议重跑即可直接并表的 base-

line [WTW*25]。DGR、X²-Gaussian 与 GR-Gaussian 则更明确地偏向 direct reconstruction、continuous-time CT 或 reconstruction-oriented CT priors,和本文的 static sparse-view NVS 主协议仍存在评价层面的偏移 [WLG*25; YCZ*25; YMS*25]。因此,我们将主实验中的直接 CT/X-ray 基线仍聚焦在与本文协议最一致的 X-Gaussian 与 R²-Gaussian 上,而把上述 2025 年后的方法作为界定最新研究边界的重要参照。

从我们的角度看,X-Gaussian 与 R²-Gaussian 已经为 CT 场景搭好了物理正确性与高效渲染的基础,但在优化层面仍保留了较多来自通用 3DGS 的默认假设。例如,初始化虽然已不再依赖 SfM,但仍缺乏对具体解剖复杂度的自适应分配;密度控制虽然可以借助梯度进行克隆与分裂,但并未显式约束边界区域的冗余堆叠;密度参数本身也仍主要依赖逐点梯度更新,而缺少连续空间上下文。因此,我们将 SPAGS 的定位放在“继承 CT-3DGS 物理基础之后,补足其空间分布建模能力”这一层面。

2.3. 我们与五个核心对比方法的关系

由于本文的对比方法恰好覆盖了 sparse-view 3DGS 与 X-ray/CT 3DGS 的两个关键谱系,因此它们也构成了定位 SPAGS 的最直接坐标系。FSGS 将 sparse-view 问题理解为“高斯不够、覆盖不足”,其方法论是补点与扩张;CoR-GS 将问题理解为“单场优化不稳定”,其方法论是通过双场 disagreement 进行无监督纠偏;DN Gaussian 将问题理解为“几何在稀疏视角下退化”,其方法论是深度先验与归一化约束;X-Gaussian 将问题理解为“自然图像版 3DGS 不适合 X 射线物理”,其方法论是辐射建模与 scanner-aware 初始化;R²-Gaussian 则进一步将问题锚定为“3DGS 在体重建场景中存在积分偏差”,并通过 kernel、rasterization 与 voxelization 做出系统修正 [ZFJW24; ZLY*24; LZB*24; CLW*24; ZLC*24]。

与这些方法相比,SPAGS 的新意并不在于重新定义 X 射线成像物理,也不在于依赖额外大模型或双场结构,而在于提出一个更贴合 CT 体空间分布

规律的优化观点：在极稀疏视角下，问题的主导项往往是结构冗余而非单纯稀疏，因而初始化、剪枝与密度调制都应该围绕“空间感知”展开。基于这一判断，我们提出的 SPS/GAP/ADM 分别对应空间感知初始化、空间感知冗余控制与空间感知密度修正，从而与上述五类代表工作形成互补而清晰的差异化路线；而对 X-Field、DGR、X²-Gaussian 与 GR-Gaussian 等更新工作，本文则把它们放在“最新边界”而非“协议直接并表”的层级上进行讨论。

3. 方法

我们将稀疏视角 CT 新视图合成拆分为三个彼此衔接的子问题：如何让初始高斯尽量落在有意义的解剖区域，如何在训练过程中抑制边界区域的冗余堆叠，以及如何让密度更新显式响应空间上下文。围绕这三个问题，我们提出 SPAGS 的三阶段框架，如图 2 所示。其核心思路并不是再引入一套额外渲染分支，而是在同一条 3DGS 优化链路上依次回答三个问题：SPS 负责“从哪里开始”，GAP 负责“哪些该删”，ADM 负责“留下来的该如何调密度”。

3.1. 符号定义与优化目标

设稀疏视角观测集合为 $\mathcal{P} = \{(I_v, \pi_v)\}_{v=1}^V$ ，其中 I_v 表示第 v 个投影， π_v 表示对应成像几何。给定 FDK 粗重建体 V_{FDK} ，SPAGS 将场景表示为高斯集合 $\mathcal{G} = \{g_i\}_{i=1}^N$ ，其中每个高斯写作

$$g_i = (\mathbf{p}_i, \Sigma_i, \rho_i, \mathbf{c}_i), \quad (1)$$

分别表示中心、协方差、密度与外观/辐射参数。对于任一视角 π_v ，R²-Gaussian 风格的辐射渲染记为

$$\hat{I}_v = \mathcal{R}(\mathcal{G}; \pi_v). \quad (2)$$

整体训练目标写为

$$\mathcal{L} = \mathcal{L}_1 + \lambda_{\text{dssim}} \mathcal{L}_{\text{dssim}} + \lambda_{\text{3DTV}} \mathcal{L}_{\text{3DTV}} + \lambda_{\text{pTV}} \mathcal{L}_{\text{pTV}}, \quad (3)$$

其中

$$\mathcal{L}_1 = \frac{1}{V} \sum_{v=1}^V \|I_v - \hat{I}_v\|_1, \quad (4)$$

$$\mathcal{L}_{\text{dssim}} = \frac{1}{V} \sum_{v=1}^V \text{DSSIM}(I_v, \hat{I}_v), \quad (5)$$

$$\mathcal{L}_{\text{3DTV}} = \sum_{i=1}^N \sum_{d \in \{x, y, z\}} |\nabla_d \rho_i|, \quad (6)$$

$$\mathcal{L}_{\text{pTV}} = \sum_{p \in \{xy, xz, yz\}} \omega_p(t) \text{TV}(P_p). \quad (7)$$

其中， $\omega_p(t)$ 为视角自适应权重， $\mathcal{L}_{\text{3DTV}}$ 用于约束体密度的空间平滑性，而 $\mathcal{L}_{\text{pTV}}$ 则对 K-Planes 特征施加平面总变分正则。

3.2. 阶段一：Spatial Prior Seeding (SPS)

SPS 回答的第一个问题是：在极少视角条件下，高斯应该从哪里开始。初始化的好坏会显著影响后续优化轨迹。标准 3DGS 往往采用均匀采样或依赖 SfM 点云初始化，但这两种方式都不适合 CT 场景：前者无法区分空气、软组织与骨骼的解剖重要性，后者则因为 X 射线投影的灰度重叠与低纹理特征难以稳定工作 [CLW*24]。我们因此使用 FDK 重建产生的粗体密度图 V_{FDK} 作为空间先验，对初始高斯进行密度加权采样：

$$p(\mathbf{x}) = \frac{(\max(V_{\text{FDK}}(\mathbf{x}), \epsilon))^\gamma}{\sum_{\mathbf{x}' \in \Omega} (\max(V_{\text{FDK}}(\mathbf{x}'), \epsilon))^\gamma}, \quad (8)$$

其中 ϵ 用于避免背景区域出现零概率， γ 控制采样集中度。

仅靠密度加权会使高斯过度聚集在亮度最高的骨性结构附近，因此我们引入混合采样：

$$\mathcal{X} = \mathcal{X}_{\text{uni}} \cup \mathcal{X}_{\text{prior}}, \quad (9)$$

其中 $|\mathcal{X}_{\text{uni}}| = \alpha M$ 、 $|\mathcal{X}_{\text{prior}}| = (1 - \alpha)M$ ， M 为初始高斯数。这样既能保证整体覆盖，又能让更多高斯优先分配给解剖复杂区域。采样位置确定后，我们将 FDK 值作为初始密度，并根据局部采样密度设定尺度参数，最终得到 50K 个初始高斯。本文中， α 与 γ 通过小范围搜索确定后保持固定，以避免在不同视角设定下引入额外的手工调参。




Figure 2: SPAGS 的总体流程。给定稀疏 CT 投影与 FDK 粗重建，SPS 负责空间先验播种，GAP 负责几何冗余回收，ADM 负责位置相关的密度修正，最终生成目标新视角 X 射线投影。




Figure 3: SPS 模块示意。利用 FDK 粗重建引导密度加权采样，使更多初始高斯落在解剖相关区域，并保留少量均匀补偿采样维持全局覆盖。

3.3. 阶段二：Geometry-aware Pruning (GAP)

GAP 回答的第二个问题是：哪些高斯其实应该被删，而不是继续补。在 CT 场景中，传统基于梯度的 densification 往往会在骨组织与软组织边界持续复制高斯，因为这些区域的投影误差梯度最大。问题在于，这类高梯度不一定意味着“覆盖不足”，也可能只是“同一结构被过多高斯竞争表示”。因此，我们不沿用 FSGS 那种面向稀疏区域补点的思路 [ZFJW24]，而是直接在世界坐标系中度量局部拥挤程度。

具体来说，对每个高斯 G_i ，我们计算其与 K 个最近邻的平均欧氏距离作为邻近度评分：

$$s_i = \frac{1}{K} \sum_{j \in \mathcal{N}_K(i)} \|\mathbf{p}_i - \mathbf{p}_j\|_2. \quad (10)$$

当 s_i 低于阈值 τ 时，说明该高斯处于过度聚集区域。为了避免误删仍在有效学习的高斯，我们再引入梯度活跃度过滤：只有当其累积位置梯度低于阈值 δ 时，才将其视为真正的冗余候选，即

$$m_i = \begin{cases} 1, & s_i \geq \tau \vee \|\nabla \mathbf{p}_i\|_1 \geq \delta, \\ 0, & \text{otherwise.} \end{cases} \quad (11)$$

实现上，GAP 不是替代 3DGS 原有的 densification，而是作为其后的周期性回收步骤运行：先沿用原始 clone/split 机制生成候选高斯，再用邻近度与梯度活跃度筛掉冗余点。最终，每轮最多剪除总高斯数的 β_{prune} ，并在第 2K 到 20K 次迭代间周期性触发。与此同时，为保持局部覆盖连续性，我们会对保留下来的密化高斯执行尺度收缩：

$$\Sigma_i^{\text{new}} = \eta \Sigma_i, \quad 0 < \eta < 1, \quad (12)$$

其中新高斯中心通常取局部最近邻的中点

$$\tilde{\mathbf{p}}_i = \frac{1}{2} (\mathbf{p}_i + \mathbf{p}_{\text{nn}(i)}), \quad \text{nn}(i) = \arg \min_{j \in \mathcal{N}_K(i)} \|\mathbf{p}_i - \mathbf{p}_j\|_2. \quad (13)$$




Figure 4: GAP 模块示意。先依据世界坐标邻近度识别局部过度聚集区域，再结合梯度活跃性过滤，仅删除学习价值较低的冗余高斯。

这一步的关键不在“减少高斯数量”本身，而在建立一种负反馈机制：当标准 3DGS 的密化策略在边界附近过度扩张时，GAP 能及时把冗余点回收，使表示容量回到真正需要的位置。

3.4. 阶段三：Adaptive Density Modulation (ADM)

ADM 回答的第三个问题是：留下来的高斯，应如何根据所在区域调整密度。即便有了更合理的初始化与冗余控制，不同解剖区域的密度更新规律仍然并不相同。骨组织应具有更高衰减系数，肺部空气区域应保持更低密度，而软组织往往需要平滑过渡。如果所有高斯都依赖相同的逐点梯度更新，模型会难以学到这种空间异质性。为此，我们引入 ADM，用 K-Planes 对高斯中心位置进行编码，并通过轻量解码器预测位置相关的密度偏移与置信度。与前两者相比，ADM 更接近一个局部修正模块：它主要负责让不同解剖区域的密度更新不再共享同一套规则，而不是单独决定整体性能上限。

给定位置 $\mathbf{x}$ ，我们从三组正交平面特征中采样并拼接成空间编码 $F(\mathbf{x})$ ：

$$f_{uv}(\mathbf{x}) = \mathcal{B}(P_{uv}, \Pi_{uv}(\mathbf{x})), \quad uv \in \{xy, xz, yz\}, \quad (14)$$

$$F(\mathbf{x}) = [f_{xy}(\mathbf{x}), f_{xz}(\mathbf{x}), f_{yz}(\mathbf{x})], \quad (15)$$

其中 $\mathcal{B}(\cdot)$ 表示双线性采样， P_{xy} 、 P_{xz} 与 P_{yz} 分别对




Figure 5: ADM 模块示意。利用 K -Planes 提供连续空间上下文，并预测位置相关的密度偏移与置信度，实现解剖区域相关的密度调制。

应三张正交特征平面。这种 K-Planes 编码最早被用于显式时空辐射场建模，能够以较低成本提供连续空间上下文 [FYT*23]。在此基础上，我们用双头 MLP 输出密度偏移 $o(\mathbf{x})$ 和置信度 $c(\mathbf{x})$ ：

$$(o(\mathbf{x}), c(\mathbf{x})) = h(F(\mathbf{x})). \quad (16)$$

随后将偏移约束在有限范围内，并结合视角自适应缩放与零均值约束：

$$\tilde{o}(\mathbf{x}) = \beta(t) s_{\text{view}} r_{\text{max}} c(\mathbf{x}) \cdot (o(\mathbf{x}) - \bar{o}), \quad (17)$$

其中 $\bar{o}$ 为当前 batch 的均值偏移， r_{max} 为最大调制范围， s_{view} 表示由视角数决定的缩放系数， $\beta(t)$ 则控制 warmup、hold 与 decay 三个阶段的调制强度。最终密度写成

$$\rho_{\text{final}}(\mathbf{x}) = \rho_{\text{base}}(\mathbf{x}) \cdot (1 + \tilde{o}(\mathbf{x})). \quad (18)$$

这样，ADM 学到的不是全局性的密度抬升，而是围绕空间上下文的相对修正，从而更符合 CT 体数据中“区域异质、局部连续”的分布特征。

3.5. 整体训练流程

SPAGS 的三阶段并非彼此独立，而是形成一个逐步收紧空间结构的优化链路：SPS 先把初始化从“无差别铺开”推进到“贴近解剖结构”，GAP 再把被错误放大的局部冗余回收回到更需要的位置，ADM 最后对保

留下来的高斯做位置相关的密度修正。若记第 t 次迭代的调制强度为 $\beta(t)$ ，则其可写成

$$\beta(t) = \begin{cases} \frac{t}{t_w}, & 0 \leq t < t_w, \\ 1, & t_w \leq t < t_h, \\ \exp\left(-\frac{t-t_h}{\tau}\right), & t \geq t_h. \end{cases} \quad (19)$$

在训练上，我们仍以 R^2 -Gaussian 的辐射渲染与重建损失为基础 [ZLC*24]，并在其上叠加空间感知模块。整体上，这一设计不改变推理阶段的基本渲染流程，因此能把额外开销主要限制在训练期间。

4. 实验

4.1. 实验设置

数据与任务设定。我们在 5 个具有代表性的器官场景上评估方法，包括 Chest、Head、Abdomen、Foot 与 Pancreas。每个场景均从完整扫描中选取训练投影，并在 2/3/4 视角条件下构造稀疏输入。该设置覆盖了高对比骨组织、低对比软组织、小器官与复杂混合组织等多种难点；其中，2-view 用于刻画极端欠定情形，4-view 用于观察在观测相对充分时的性能上限，而 3-view 则是后续分析的重点，因为它最能反映实际稀疏 CT 中“信息紧张但仍可被先验纠正”的工作区间。

对比方法。我们选取 5 个与本文最相关的 3DGS 基线：DNGaussian [LZB*24]、CoR-GS [ZLY*24]、FSGS [ZFYJW24]、X-Gaussian [CLW*24] 以及 R^2 -Gaussian [ZLC*24]。其中前三者分别代表自然图像 sparse-view 3DGS 中较典型的几何正则、协同抑制和补点扩张路线，后两者则提供了面向 X 射线与 CT 场景的直接辐射式对比基础。

实现细节。SPS 使用 $\alpha = 0.2$ 、 $\gamma = 1.0$ 与 50K 初始高斯；GAP 采用 $K = 5$ 邻居、阈值 $\tau = 0.015$ 、最大剪枝比 $\beta = 0.02$ 、梯度阈值 $\delta = 0.0002$ ；ADM 采用分辨率 64 的 K-Planes、特征维度 32，并在 15K 次迭代后启动。所有模型训练 30K 次迭代，主文以 PSNR 作为核心评价指标，并使用 SSIM 作为补充图像结构指标。

4.2. 主结果

表 1 汇报了 2/3/4 视角下的主对比结果。结果首先支持了本文最核心的主张：SPAGS 的收益主要出现在“信息紧张但仍可被空间先验有效纠正”的区间。具体而言，在最有实际价值的 3-view 设定下，SPAGS 以 28.22 dB 的平均 PSNR 超过 R^2 -Gaussian 的 27.83 dB，并在五个器官中取得更稳定的整体优势；而在 2-view 时，所有方法都受到更强的欠定约束，局部优化很难稳定收敛；在 4-view 时，随着观测逐渐充分，各方法差距被自然压缩。

从结果分布上看，SPAGS 的增益并不是平均摊在所有设定上的，而是集中体现在 3-view 这个最关键的工作点。这一点很重要，因为它说明我们的方法并不是简单地“在任何情况下都多加一点修正”，而是在基线尚未自然收敛、但空间感知信息仍然足以改变优化轨迹时，最有效地重新分配表示容量。换句话说，SPAGS 真正改善的是稀疏视角 CT 中最难也最有价值的那一段优化区间。与此同时，2-view 的 Foot 和 Pancreas 仍然是最弱的两个场景，说明当前方法并不是极端欠定条件下的通用解；当观测过少时，FDK 先验和局部空间修正都不足以完全抵消信息缺失。

虽然主文以 PSNR 作为主指标，但 SSIM 的补充比较给出了与主结果一致的整体趋势：在 3-view 五器官平均上，SPAGS 的 SSIM 从 R^2 -Gaussian 的 0.9025 提升到 0.9057，并在 Chest、Abdomen、Pancreas 与 Foot 上保持一致改进，仅在 Head 上出现轻微波动。这说明本文关于“3-view 设定最受益、GAP 是主要性能来源”的结论并不依赖单一指标。由于篇幅限制，全量 SSIM 对比放在补充材料中。

图 6 展示了 3-view 设定下的主定性对比。面向自然图像的 3DGS 基线更容易出现条纹状或云雾状伪影，且结构边界会随视角稀疏程度加剧漂移； R^2 -Gaussian 与 SPAGS 则能更稳定地恢复符合 X 射线成像特性的整体解剖轮廓。在 Chest 与 Pancreas 等更具挑战的场景中，SPAGS 的优势并不只是把边缘做得更锐，而是在保持主体灰度分布的同时，进一步压低背景噪声、边缘扩散与局部外溢，这与“回收被错误放大的边界冗余”这一方法目标是一致的。

Table 1: 五个器官在 2/3/4 视角下的 PSNR 对比 (dB, $\uparrow$)。最优加粗，次优下划线。

Method	Chest			Head			Abdomen		
	2v	3v	4v	2v	3v	4v	2v	3v	4v
DN-Gaussian	14.30	16.02	15.76	15.72	18.04	16.24	19.33	23.51	24.72
CoR-GS	14.96	18.55	20.29	16.24	20.36	23.40	18.50	22.45	23.03
FSGS	17.86	19.99	21.03	19.43	21.53	24.91	18.75	23.34	23.63
X-Gaussian	17.79	20.29	20.90	19.62	21.52	24.46	18.93	23.54	23.85
R ² -Gaussian	<u>21.05</u>	<u>26.22</u>	<u>25.47</u>	<u>23.54</u>	<u>26.60</u>	28.66	<u>24.85</u>	<u>29.26</u>	<u>30.56</u>
SPAGS	21.26	26.81	25.83	23.63	26.63	<u>28.52</u>	24.97	29.73	30.89

Method	Foot			Pancreas			Avg		
	2v	3v	4v	2v	3v	4v	2v	3v	4v
DN-Gaussian	20.17	23.51	19.33	16.15	22.43	25.47	17.13	20.70	20.30
CoR-GS	20.17	25.53	26.83	16.15	23.25	23.96	17.20	22.03	23.50
FSGS	<u>22.17</u>	25.37	27.08	<u>23.03</u>	25.27	26.22	20.25	23.10	24.57
X-Gaussian	22.34	25.48	26.92	23.21	25.12	25.55	20.38	23.19	24.34
R ² -Gaussian	19.39	<u>28.48</u>	30.04	17.83	<u>28.61</u>	30.90	<u>21.33</u>	<u>27.83</u>	<u>29.13</u>
SPAGS	19.55	28.49	<u>29.86</u>	17.80	29.43	30.90	21.44	28.22	29.20

图 7 左侧进一步放大了肋骨边界与颅骨边界附近的局部区域，可以看到 SPAGS 比 R²-Gaussian 及自然图像基线保留了更平滑的组织过渡与更干净的边缘响应。右侧的跨视角一致性对比则表明，在不同目标角度下，SPAGS 的形态变化更稳定，没有明显的角度特异性伪影。

4.3. 消融实验

表 2 汇报了 3-view 设定下的模块消融结果。结果最清楚地表明，GAP 是最稳定的增益来源：在最关键的 3-view 设定下，只加入 GAP 就能带来 +0.42 dB 的提升，并达到完整模型水平；SPS 提供更好的初始化起点，ADM 则更多体现在与前两者结合后的稳定修正作用。

图 8 进一步给出了模块递进带来的可视化差异与空间结构解释。上半部分展示了 Baseline、+GAP 与 Full 的渐进式消融结果：仅使用 GAP 时，边界附近最显著的高亮伪影就已被明显抑制；在此基础

Table 2: 3-view 设定下的模块消融。汇报五个器官平均 PSNR 及相对 R²-Gaussian 的增益 Δ 。

Config	SPS	GAP	ADM	PSNR $\uparrow$	$\Delta \uparrow$
Baseline				27.80	—
+SPS	✓			28.01	+0.21
+GAP		✓		28.22	+0.42
+ADM			✓	27.91	+0.11
+SPS+ADM	✓		✓	<u>28.09</u>	<u>+0.29</u>
+SPS+GAP	✓	✓		28.22	+0.42
Full	✓	✓	✓	28.22	+0.42

上，完整模型还能继续稳定局部灰度过渡。下半部分则从高斯空间分布角度解释了这一收益来源：SPS 先将初始化从完全均匀推进到更贴合粗重建的区域，GAP 再剔除外围冗余点，最终 SPAGS 在更紧致的空间支撑上完成渲染。




Figure 6: 3-view 设定下的主定性对比。每一行对应一个器官场景，最左列给出三张输入训练投影，其余列展示同一目标视角下的真值与各方法输出。与面向自然图像的 *sparse-view 3DGS* 基线相比， R^2 -Gaussian 与 SPAGS 更符合 X 射线结构分布，而 SPAGS 在胸腔背景、头部轮廓和胰腺区域进一步压低了伪影与边界扩散。

4.4. 结构冗余机制分析

前面的消融表明 GAP 是主要增益来源，但表格本身还不能说明它到底改变了什么空间结构。图 8 提供了一个更直接的机制视角：SPS 先把高斯支撑从完全均匀拉到更贴近解剖区域的范围内，GAP 再优先回收边界处过度聚集的冗余高斯，而 ADM 则在这一更紧致的支撑上做局部密度修正。换句话说，SPAGS 的收益不是单纯来自“更多点”，而是来自把表示容量从边界高密度簇中释放出来，并重新分配到更有结构意义的位置上。

这一点也解释了为什么 +GAP 和 Full 在 PSNR 上几乎并列：GAP 已经完成了最主要的空间重分配，而 ADM 的作用更多体现在局部灰度过渡与训练稳定性上，而不是继续抬高平均分数。因此，当前版本

中我们把 ADM 定位为辅助稳定模块，而不是主要性能驱动。这个机制分析目前仍主要依赖可视化证据，后续若进一步补充边界区域的密度统计和 pruning 分布统计，可以把这一判断做得更硬。

4.5. 超参数设置与效率分析

我们将最终采用的关键超参数整理在表 3 中。整体来看，SPS 与 ADM 的可行区间相对较宽，而 GAP 的阈值与最大剪枝比更敏感。这一现象进一步支持了本文的核心结论：决定性能上限的关键不在于是否继续增加高斯，而在于冗余控制强度是否落在合适区间；一旦剪枝过弱，冗余边界会继续吞噬表示容量，剪枝过强则会损伤有效结构。

图 9 从效率与优化过程两个角度给出了补充证

Table 3: 关键超参数与最终采用配置。对经过调参的项目，同时给出验证时使用的搜索空间。

模块	参数	搜索空间	最终设置
SPS	uniform ratio α	0.2 / 0.3 / 0.4	0.2
SPS	density exponent γ	0.7 / 0.8 / 1.0	1.0
SPS	initialization mode	raw / valid mean	raw
SPS	initialized Gaussians M	50K / 75K	50K
GAP	neighbor count K	fixed	5
GAP	pruning threshold τ	0.010 / 0.015 / 0.020	0.015
GAP	max pruning ratio β	2% / 3% / 5%	2%
GAP	start iteration	1K / 2K / 5K	2K
GAP	stop iteration	15K / 20K / 30K	20K
ADM	warm-up iteration	12K / 15K / 18K	15K
ADM	max modulation range	0.2 / 0.3 / 0.4	0.3
ADM	K-Planes resolution	64 / 128	64
ADM	feature dimension C	fixed	32

据。上图显示，SPAGS 在接近 R^2 -Gaussian 推理速度的同时位于更优的 PSNR-FPS 权衡前沿；下图则表明，无论按迭代次数还是按 wall-clock time 统计，SPAGS 都能更早达到更高的 PSNR 平台。按当前实现，SPS/GAP/ADM 带来的额外训练开销控制在 10% 以内，而推理端基本保持同一量级，这说明性能提升并没有以明显牺牲部署效率为代价。

4.6. 讨论

主结果、消融实验与超参数分析共同支持了一个更具体的结论：在稀疏视角 CT 场景中，真正决定性能上限的往往不是“是否继续补更多高斯”，而是“能否在空间上把高斯放对位置，并及时回收被错误放大的冗余结构”。这也是为什么 GAP 在我们的设定里表现得比 SPS 与 ADM 更强。需要强调的是，这并不意味着稀疏 CT 完全不需要密化，而是说明密化必须建立在空间感知初始化和冗余回收之上；否则，新增表示容量往往会优先被高梯度边界吞噬。另一方面，SPS 与 ADM 的价值并不主要体现在单独拉高平均分数，而是为训练过程提供更好的起点和更稳定的密度修正机制；它们使 GAP 的剪枝判断更可靠，也使最终密度分布更平滑，从而在更广泛的器官与视角设置下保持稳定收益。

图 10 进一步给出了两个最具代表性的 failure cases: 2-view Foot 与 2-view Pancreas。在这两种极端欠定场景下，SPAGS 仍能在部分区域压低局部外溢与条纹残差，但无法稳定恢复所有缺失结构，尤其是当投影信息本身不足以唯一约束体密度分布时，初始化与局部修正都难以完全弥补观测缺口。这一现象与主结果中的数值分布是一致的，也进一步说明本文方法最有效的工作区间仍是 3-view 这类中等稀疏设置，而不是 2-view 极端欠定设置。




Figure 7: 局部细节与跨视角一致性分析。上：两组放大 ROI，对比肋骨/颅骨边界附近的局部结构与软组织过渡。下：同一病例在三个目标角度下的结果，SPAGS 相比 R^2 -Gaussian 保持了更稳定的跨视角形态，并减少了角度特异性伪影。




Figure 8: 结构冗余机制的可视化分析。上：3-view 设定下的渐进式消融可视化，展示 *Baseline*、*+GAP* 与 *Full* 在两组 *Chest* 案例上的预测结果及残差图。仅加入 *GAP* 时已能去除主要伪影，完整模型则进一步稳定局部灰度过渡。下：高斯空间分布的逐步收紧过程。从均匀初始化到 *SPS* 引导初始化，再到 *GAP* 剪枝与最终 *SPAGS*，高斯支撑逐步贴合有效结构区域。




Figure 9: 效率与收敛分析。左: 不同方法的 $PSNR$ - FPS 权衡, 圆点大小表示最终 $Gaussian$ 数量。右: $SPAGS$ 与 R^2 - $Gaussian$ 在 3-view *Chest* 场景上的 $PSNR$ 收敛曲线, 分别按迭代次数和 *wall-clock time* 统计。




Figure 10: 2-view 极端稀疏设置下的 *failure cases*。展示 *Foot* 与 *Pancreas* 两个最具挑战性的场景, 并对比 R^2 - $Gaussian$ 、 $SPAGS$ 及其残差。可以看到, $SPAGS$ 虽能在局部压低外溢与噪声, 但在观测严重不足时仍无法完全恢复缺失结构。

5. 结论

本文提出 SPAGS, 面向稀疏视角 CT 新视图合成, 在 3DGS 管线的初始化、密度控制与密度调制三个阶段显式引入空间感知。与已有 sparse-view 3DGS 方法主要围绕补点、深度正则或双场协同不同, 我们强调 CT 体数据中的主要矛盾往往不是单纯稀疏, 而是结构冗余被高梯度边界持续放大, 并据此提出 SPS/GAP/ADM 三个互补模块。实验结果表明, SPAGS 在 5 个器官、2/3/4 视角设定中取得提升, 尤其在最核心的 3-view 条件下, 相比 R^2 -Gaussian 获得 0.39 dB 的平均 PSNR 增益; 其中 GAP 是主要性能驱动, SPS 负责提供更好的初始化起点, 而 ADM 主要用于稳定局部密度修正。

5.0.0.1. 局限性。 当前工作也有两个边界需要如实说明: 一是方法最有效的区间仍是 3-view 这类中等稀疏设置, 在 2-view 极端欠定场景下提升会明显受限, 这一点在图 10 的 Foot 和 Pancreas 案例中表现得尤为明显; 二是 SPS 依赖 FDK 粗重建作为空间先验, 因此当初始先验质量较差时, 初始化优势也会相应减弱。

当前工作仍有若干值得继续推进的方向。首先, ADM 的特征分辨率与调制范围目前对不同器官共享, 未来可以探索跨器官自适应配置; 其次, 本文主要评估静态稀疏视角 CT, 如何扩展到 cone-beam 或 4DCT 场景仍值得深入研究; 最后, 若能将病例级优化与更强的学习型体先验结合, SPAGS 还有望在极端稀疏条件下进一步提升稳定性。

References

- [AK84] ANDERSEN, A. H. and KAK, A. C. “Simultaneous Algebraic Reconstruction Technique (SART): A Superior Implementation of the ART Algorithm”. *Ultrasonic Imaging* 6.1 (1984), 81–94 1, 3.
- [CLW*24] CAI, YUANHAO, LIANG, YIXUN, WANG, JIAHAO, et al. “Radiative Gaussian Splatting for Efficient X-ray Novel View Synthesis”. *European Conference on Computer Vision (ECCV)*. 2024 2, 4, 5, 8.
- [CW24] CHEN, GUIKUN and WANG, WENGUAN. “A Survey on 3D Gaussian Splatting”. *arXiv preprint arXiv:2401.03890* (2024) 2.
- [CWC*22] CHEN, YINBO, WANG, SIYU, CHEN, XIAOLONG, et al. “pixelNeRF: Neural Radiance Fields from One or Few Images”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022 3.
- [CXG*22] CHEN, ANPEI, XU, ZEXIANG, GEIGER, ANDREAS, et al. “TensorRF: Tensorial Radiance Fields”. *European Conference on Computer Vision (ECCV)*. 2022 4.
- [FDK84] FELDKAMP, L. A., DAVIS, L. C., and KRESS, J. W. “Practical Cone-Beam Algorithm”. *Journal of the Optical Society of America A* 1.6 (1984), 612–619 1, 3.
- [FYT*23] FRIDOVICH-KEIL, SARA, YU, GIAN, TANCİK, MATTHEW, et al. “K-Planes: Explicit Radiance Fields in Space, Time, and Appearance”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2023 7.
- [GL24] GUÉDON, ANTOINE and LEPETIT, VINCENT. “SuGaR: Surface-Aligned Gaussian Splatting for Efficient 3D Mesh Reconstruction and High-Quality Mesh Rendering”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [GWS*24] GUAN, QIANG, WANG, JIARUI, SHEN, LIYUE, et al. “NAF: Neural Attenuation Fields for Sparse-View X-ray Imaging”. *Medical Image Analysis* (2024) 3.
- [KKLD23] KERBL, BERNHARD, KOPANAS, GEORGIOS, LEIMKÜHLER, THOMAS, and DRETTAKIS, GEORGE. “3D Gaussian Splatting for Real-Time Radiance Field Rendering”. *ACM Transactions on Graphics* 42.4 (2023), 1–14 2.
- [LYX*24] LU, TAO, YU, MULIN, XU, LINNING, et al. “ScaffoldGS: Structured 3D Gaussians for View-Adaptive Rendering”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [LZB*24] LI, JIAHE, ZHANG, JIAWEI, BAI, XIAO, et al. “DNGaussian: Optimizing Sparse-View 3D Gaussian Radiance Fields with Global-Local Depth Normalization”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2–4, 8.
- [MESK22] MÜLLER, THOMAS, EVANS, ALEX, SCHIED, CHRISTOPH, and KELLER, ALEXANDER. “Instant Neural Graphics Primitives with a Multiresolution Hash Encoding”. *ACM Transactions on Graphics (SIGGRAPH)*. Vol. 41. 4. 2022, 1–15 4.
- [MST*21] MILDENHALL, BEN, SRINIVASAN, PRATUL P., TANCİK, MATTHEW, et al. “NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis”. *Communications of the ACM* 65.1 (2021), 99–106 3.
- [NMKW24] NAVANEET, K., MEIBODI, KOOSHK, KOIKE-AKINO, TOSHIKI, and WANG, YIBO. “Compact 3D Gaussian Splatting for Sparse View Rendering”. *arXiv preprint arXiv:2311.18159* (2024) 3.

- [RNSZ24] RÖSSLE, BARBARA, NIESSNER, MATTHIAS, SEIDEL, HANS-PETER, and ZOLLHÖFER, MICHAEL. “Densification Strategies for 3D Gaussian Splatting”. *arXiv preprint arXiv:2401.17151* (2024) 3.
- [SGW*24] SHEN, LIYUE, GUAN, QIANG, WANG, JIARUI, et al. “SAX-NeRF: Learning X-Ray Volume Reconstruction via Statistical and Anatomical Coordinates”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 3.
- [WCLL23] WANG, GUANGCONG, CHEN, ZHAOXI, LOY, CHEN CHANGE, and LIU, ZIWEI. “SparseNeRF: Distilling Depth Ranking for Few-Shot Novel View Synthesis”. *arXiv preprint arXiv:2303.16196* (2023) 3.
- [WLG*25] WU, SHAKAI, LU, YUXIANG, GUO, YAPAN, et al. “Discretized Gaussian Representation for Tomographic Reconstruction”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2025, 25073–25082 4.
- [WRW*24] WU, ZIYI, REN, JIAWEI, WANG, XIAO, et al. “4D Gaussian Splatting for Real-Time Dynamic Scene Rendering”. *arXiv preprint arXiv:2310.08528* (2024) 2.
- [WTW*25] WANG, FEIRAN, TAO, JIACHEN, WU, JUNYI, et al. “X-Field: A Physically Informed Representation for 3D X-ray Reconstruction”. *Advances in Neural Information Processing Systems (NeurIPS)*. 2025 4.
- [WYD08] WANG, GE, YU, HENGYONG, and DE MAN, BRUNO. “An Outlook on X-Ray CT Research and Development”. *Medical Physics* 35.3 (2008), 1051–1064 1.
- [XLG*24] XU, LINNING, LI, JIAMING, GAO, JINGKAI, et al. “Grid-Guided Gaussian Splatting for Large-Scale Outdoor Scene Rendering”. *arXiv preprint arXiv:2403.11852* (2024) 3.
- [XPW*25] XU, HAOFEI, PENG, SONGYOU, WANG, FANGJINHUA, et al. “DepthSplat: Connecting Gaussian Splatting and Depth”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025 3.
- [YCH*24] YU, ZEHAO, CHEN, ANFEI, HUANG, BINBIN, et al. “Mip-Splatting: Alias-free 3D Gaussian Splatting”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024 2.
- [Y CZ*25] YU, WEIHAO, CAI, YUANHAO, ZHA, RUYI, et al. “X²-Gaussian: 4D Radiative Gaussian Splatting for Continuous-Time Tomographic Reconstruction”. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2025 4.
- [YGZ*24] YANG, ZEYU, GAO, BINGLIANG, ZHOU, YIBO, et al. “Deformable 3D Gaussian Splatting for High-Fidelity Monocular Dynamic Scene Reconstruction”. *arXiv preprint arXiv:2309.13101* (2024) 3.
- [YMS*25] YULUO, YIKUANG, MA, YUE, SHEN, KUAN, et al. “GR-Gaussian: Graph-Based Radiative Gaussian Splatting for Sparse-View Tomographic Reconstruction”. *arXiv preprint arXiv:2508.02408* (2025) 4.
- [YPW23] YANG, JIAWEI, PAVONE, MARCO, and WANG, YUE. “FreeNeRF: Improving Few-Shot Neural Rendering with Free Frequency Regularization”. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2023 3.
- [ZFJW24] ZHU, ZEHAO, FAN, ZHIWEN, JIANG, YIFAN, and WANG, ZHANGYANG. “FSGS: Real-Time Few-Shot View Synthesis Using Gaussian Splatting”. *European Conference on Computer Vision (ECCV)*. 2024 2–4, 6, 8.
- [ZLC*24] ZHA, RUYI, LIN, TAO JUN, CAI, YUANHAO, et al. “R²-Gaussian: Rectifying Radiative Gaussian Splatting for Tomographic Reconstruction”. *Advances in Neural Information Processing Systems (NeurIPS)*. 2024 2, 4, 8.
- [ZLY*24] ZHANG, JIAWEI, LI, JIAHE, YU, XIAOHAN, et al. “CoR-GS: Sparse-View 3D Gaussian Splatting via Co-Regularization”. *European Conference on Computer Vision (ECCV)*. 2024 2–4, 8.
- [ZZL*23] ZHA, RUNZHAO, ZHANG, HAOTIAN, LIU, MING, et al. “NeRF for Medical Imaging: A Survey”. *arXiv preprint arXiv:2307.00347* (2023) 3.